

L'interaction bidirectionnelle entre intelligence artificielle et informatique quantique*

Un état des lieux vérifié à la mi-2026

André-Guy Bruneau
Recherche indépendante
agbruneau@gmail.com

3 juillet 2026

Résumé L'intelligence artificielle (IA) et l'informatique quantique entretiennent une relation bidirectionnelle dont les deux sens connaissent des fortunes très inégales. Cet article dresse un état des lieux de cette interaction, arrêté à juillet 2026 et fondé exclusivement sur des énoncés confrontés à leurs sources primaires par un protocole de vérification adversariale multi-agents. Trois constats structurent la synthèse. Premièrement, la direction « IA pour le quantique » a produit des résultats mesurables et, pour partie, reproduits : les décodeurs neuronaux de codes correcteurs d'erreurs surpassent désormais les meilleurs décodeurs classiques connus en précision (AlphaQubit, publié dans Nature en 2024) et atteignent, en préprint, le décodage en temps réel sous la microseconde par cycle (AlphaQubit 2) ; l'apprentissage par renforcement unifie calibration et calcul sur un processeur réel ; la conception de circuits assistée par IA égale des optimisations humaines de référence (AlphaTensor-Quantum, Nature Machine Intelligence 2025) ; les états quantiques neuronaux rivalisent avec les méthodes établies de chimie quantique (Science 2024). Deuxièmement, la direction inverse — l'apprentissage automatique quantique (QML) au service de l'IA — demeure contrainte par des obstacles théoriques profonds (plateaux stériles, simulabilité classique des modèles sans plateau), et ne présente, à mi-2026, aucun avantage pratique démontré sur données classiques ; les avantages rigoureusement prouvés concernent soit des données intrinsèquement quantiques (Science 2022), soit des constructions reposant sur des hypothèses cryptographiques et exigeant la tolérance aux fautes (Nature Physics 2021). Troisièmement, une convergence systémique s'accélère au niveau des infrastructures : couplage HPC-quantique à faible latence (NVIDIA NVQLink, octobre 2025), décodage temps réel hétérogène (IBM, Google) et feuilles de route industrielles convergeant, en promesse, vers la tolérance aux fautes à l'horizon 2029. Nous documentons la méthodologie de vérification, distinguons systématiquement annonce commerciale, préprint et publication à comité de lecture, et identifions les questions ouvertes qui décideront de la trajectoire du domaine.

Table des matières

1. Introduction	2
2. Cadre conceptuel et terminologie	4
2.1 Trois directions d'interaction	4
2.2 Repères techniques	4
3. L'IA au service du calcul quantique	5
3.1 Décodage neuronal des codes correcteurs d'erreurs	5
3.2 Calibration et contrôle par apprentissage par renforcement	7
3.3 Conception de circuits et découverte de codes	8
3.4 Simulation neuronale des systèmes quantiques	9
4. Le calcul quantique au service de l'IA	9
4.1 Les plateaux stériles, obstacle structurel	9
4.2 La vague de la simulabilité classique	10
4.3 Les avantages prouvés, et leur périmètre exact	11
5. La convergence systémique des infrastructures	12
5.1 Le couplage HPC-quantique à faible latence	12
5.2 Les jalons matériels revus par les pairs	13
5.3 Une controverse révélatrice : les qubits topologiques	14
5.4 Feuilles de route et modèles de langage pour la programmation quantique	15
6. Confronter promesses et réalités	15
7. Questions ouvertes	17
8. Méthodologie et limites	18
8.1 Protocole de recherche et de vérification	18
8.2 Limites	18
9. Conclusion	19
Remerciements	20
Références	20

Mots-clés — intelligence artificielle ; informatique quantique ; correction d'erreurs quantiques ; décodeurs neuronaux ; apprentissage automatique quantique ; états quantiques neuronaux ; apprentissage par renforcement ; convergence HPC-quantique ; plateaux stériles ; simulabilité classique.

1. Introduction

L'informatique quantique et l'intelligence artificielle sont régulièrement présentées comme les deux technologies de rupture de la décennie, et leur rencontre suscite un enthousiasme considérable — enthousiasme qu'accompagnent, dans des proportions comparables, la confusion terminologique et l'inflation promotionnelle. Derrière l'étiquette commode d'« IA quantique »

*Document de synthèse produit avec l'assistance d'agents d'intelligence artificielle (Claude, Anthropic) pour la recherche documentaire, la vérification des sources et la mise en forme, sous direction et responsabilité éditoriales humaines. Chaque énoncé factuel central a été soumis à une vérification contre sa source primaire (protocole décrit à la section 8). Ce document n'a pas été soumis à arXiv ; il en adopte les conventions de forme.

coexistent en réalité des programmes de recherche radicalement différents, aux degrés de maturité incommensurables : utiliser l'apprentissage automatique classique pour construire, contrôler et corriger les ordinateurs quantiques ; utiliser des processeurs quantiques pour accélérer ou enrichir l'apprentissage automatique ; et intégrer les deux paradigmes au sein d'infrastructures de calcul hybrides. Confondre ces directions, c'est s'interdire de comprendre où le progrès est réel, où il est espéré, et où il est simplement affirmé.

Le présent article propose un état des lieux de cette interaction bidirectionnelle, arrêté à juillet 2026. Il vise trois contributions. Premièrement, une **cartographie structurée** de l'interaction en trois volets — l'IA au service du calcul quantique (section 3), le calcul quantique au service de l'IA (section 4), et la convergence systémique des infrastructures (section 5) — complétée par une analyse critique des échéanciers et du discours d'accompagnement (sections 6 et 7). Deuxièmement, une **discipline de preuve** : chaque énoncé factuel central de cette synthèse a été extrait d'une source primaire (article de revue, préprint arXiv, annonce officielle), puis confronté à cette source ; les énoncés réfutés ou non confirmés sont écartés ou explicitement signalés (la méthodologie est détaillée en section 8). Troisièmement, une **hiérarchisation épistémique** systématique : nous distinguons à chaque fois ce qui relève de la publication à comité de lecture, du préprint auto-rapporté non répliqué, ou de l'annonce industrielle, et nous attribuons les chiffres de performance à leurs auteurs plutôt que de les énoncer comme des faits établis lorsqu'aucune réplcation indépendante n'existe.

Le résultat central de cette cartographie tient en une asymétrie. À mi-2026, la direction « IA pour le quantique » est celle où l'interaction produit des résultats vérifiables de bout en bout : des décodeurs neuronaux plus précis que les meilleures méthodes classiques connues, validés sur données expérimentales et publiés dans des revues à comité de lecture [6] ; des agents d'apprentissage par renforcement qui calibrent un processeur quantique pendant qu'il calcule [9] ; des systèmes de conception automatique qui redécouvrent — puis égalent — des optimisations de circuits dues aux meilleurs spécialistes humains [11]. La direction inverse, l'apprentissage automatique quantique, traverse au contraire une phase de consolidation critique : les résultats théoriques sur les plateaux stériles [25] et la simulabilité classique des modèles sans plateau [26] ont resserré l'espace des avantages quantiques plausibles en apprentissage, et le consensus émergent réserve ces avantages aux données intrinsèquement quantiques [29] plutôt qu'aux données classiques qui dominent l'industrie de l'IA. Entre les deux, la convergence des infrastructures — interconnexions GPU-QPU à faible latence [33], décodage temps réel [32,35], feuilles de route vers la tolérance aux fautes [35,39] — avance à un rythme industriel soutenu, mais son calendrier reste suspendu à des jalons scientifiques qui ne sont pas tous acquis, comme l'illustre la controverse sur les qubits topologiques (section 5.3).

Le reste de l'article est organisé comme suit. La section 2 fixe le cadre conceptuel et la terminologie. Les sections 3 à 5 déploient les trois volets de l'interaction. Les sections 6 et 7 confrontent promesses et réalités mesurées, puis recensent les questions ouvertes dont la résolution déterminera la trajectoire du domaine. La section 8 documente la méthodologie de recherche et de vérification, ainsi que ses limites, et la section 9 conclut.

2. Cadre conceptuel et terminologie

2.1 Trois directions d'interaction

Nous adoptons la taxonomie suivante, qui structure l'ensemble de l'article.

IA pour le quantique ($\text{IA} \rightarrow \text{Q}$). L'apprentissage automatique classique est appliqué aux problèmes internes de l'informatique quantique : décodage des codes correcteurs d'erreurs, calibration et contrôle des qubits, compilation et optimisation de circuits, découverte de codes correcteurs, et simulation classique de systèmes quantiques par réseaux de neurones. Dans cette direction, l'ordinateur quantique est l'*objet* de l'IA, non son substrat : les modèles s'exécutent sur du matériel classique (GPU, TPU, FPGA) et traitent des données produites par — ou destinées à — des processeurs quantiques.

Quantique pour l'IA ($\text{Q} \rightarrow \text{IA}$). Des circuits quantiques, généralement paramétrés et optimisés variationnellement, servent de modèles d'apprentissage : réseaux de neurones quantiques, méthodes à noyaux quantiques, modèles génératifs quantiques. La promesse est ici qu'un espace de Hilbert exponentiellement grand offre des représentations inaccessibles aux modèles classiques ; l'obstacle, que cette expressivité se paie en entraînabilité et que des algorithmes classiques parviennent souvent à reproduire les performances annoncées — phénomène que la littérature nomme, de façon relâchée, *dequantization* (simulabilité classique).

Convergence systémique ($\text{IA} \rightleftharpoons \text{Q}$). Au-delà des algorithmes, les deux paradigmes s'intègrent au niveau des infrastructures : supercalculateurs couplant GPU et processeurs quantiques, décodage de correction d'erreurs délocalisé sur accélérateurs classiques, environnements de programmation unifiés, et modèles de langage assistant la programmation quantique. Cette direction est autant industrielle que scientifique, et son analyse exige de distinguer soigneusement l'annonce du résultat.

2.2 Repères techniques

Quelques notions reviennent tout au long de la synthèse. Un *code correcteur d'erreurs quantique* protège l'information logique en la répartissant sur de nombreux qubits physiques ; le *code de surface* et le *code de couleur* en sont les variantes topologiques dominantes, caractérisées par une *distance* (le nombre minimal d'erreurs physiques pouvant produire une erreur logique). Le *décodeur* est l'algorithme classique qui, à partir des mesures de syndrome, infère la correction à appliquer ; il doit idéalement fonctionner en *temps réel*, c'est-à-dire suivre la cadence des cycles de correction (de l'ordre de la microseconde pour les qubits supraconducteurs) sans accumuler de retard. Le régime *NISQ* (*noisy intermediate-scale quantum*) désigne les processeurs actuels, bruités et sans correction d'erreurs complète, par opposition au calcul quantique *tolérant aux fautes* (FTQC) visé par les feuilles de route industrielles. Les *algorithmes variationnels* (VQE, QAOA) optimisent classiquement les paramètres d'un circuit quantique ; les *plateaux stériles* (*barren plateaus*) désignent l'aplatissement exponentiel de leur paysage d'optimisation, qui compromet l'entraînement à grande échelle. Enfin, la *simulabilité classique* (ou *dequantization*) désigne la découverte d'algorithmes classiques reproduisant, à coût comparable, des performances initialement attribuées à un avantage quantique.

3. L’IA au service du calcul quantique

Cette direction est, à mi-2026, la plus solidement étayée des trois. Elle progresse sur quatre fronts complémentaires qui couvrent l’essentiel du cycle de vie d’un ordinateur quantique : décoder ses erreurs (§3.1), le calibrer et le contrôler (§3.2), concevoir ses circuits et ses codes (§3.3), et simuler classiquement les systèmes quantiques qu’il prétend un jour surpasser (§3.4).

3.1 Décodage neuronal des codes correcteurs d’erreurs

La correction d’erreurs est le verrou central du calcul quantique utile, et le décodage en est la composante algorithmique critique : un décodeur plus précis abaisse le taux d’erreur logique à matériel constant, ce qui équivaut à améliorer les qubits sans toucher au laboratoire. C’est sur ce terrain que l’apprentissage automatique a remporté ses succès les plus nets.

La lignée des décodeurs neuronaux est antérieure aux systèmes médiatisés récents. Dès 2018, Baireuther *et al.* montrent qu’un réseau récurrent LSTM, entraîné uniquement sur des données expérimentalement accessibles, surpasse le décodeur classique par appariement parfait de poids minimal (MWPM) pour le code de surface, en capturant les corrélations entre erreurs de bit et de phase que l’appariement ignore [1]. Des réseaux de neurones sur graphes reproduisent ensuite ce dépassement sur données simulées, sans modèle de bruit explicite [2], et les architectures à attention font leur entrée dans le décodage en 2023, avec des taux d’erreur logique inférieurs aux références MWPM et Union-Find [3] ; la revue d’Alexeev *et al.* retrace cette généalogie [4]. Un décodeur neuronal indépendant confirme par ailleurs une réduction d’environ 25 % du taux d’erreur logique par rapport au MWPM sur les données expérimentales de Google [5].

Le point de bascule en précision est AlphaQubit (Google DeepMind et Google Quantum AI), publié dans *Nature* fin 2024 [6]. Ce décodeur récurrent à base de transformeurs établit l’état de l’art sur les données expérimentales du processeur Sycamore : un taux d’erreur logique de $(2,901 \pm 0,023) \times 10^{-2}$ à distance 3 et $(2,748 \pm 0,015) \times 10^{-2}$ à distance 5, inférieur à celui du décodeur à réseaux de tenseurs — la méthode la plus précise connue jusqu’alors pour cette expérience, à $(3,028 \pm 0,023) \times 10^{-2}$ et $(2,915 \pm 0,016) \times 10^{-2}$ respectivement — soit des écarts d’environ 4 et 7 écarts-types. En simulation réaliste (bruit corrélé, fuites de niveaux, diaphonie, lectures analogiques), l’avantage sur l’appariement corrélé se maintient jusqu’à la distance 11, soit de 17 à 241 qubits physiques [6]. La publication dans une revue à comité de lecture et la validation sur données expérimentales réelles font de ce résultat le point d’ancrage le plus solide de toute la direction IA→Q.

Restait l’obstacle du débit : la précision d’AlphaQubit ne satisfaisait pas la contrainte de temps réel des processeurs supraconducteurs, dont le budget est de l’ordre de la microseconde par cycle de correction. C’est précisément ce verrou que vise AlphaQubit 2 (préprint arXiv, décembre 2025, révisé en mars 2026), qui rapporte des taux d’erreur logique quasi optimaux pour les codes de surface (distances testées 3 à 23) et de couleur (jusqu’à la distance 27) sous bruit réaliste, un décodage en temps réel sous la microseconde par cycle sur accélérateurs commerciaux jusqu’à la distance 11 pour le code de surface — avec une précision supérieure aux décodeurs temps réel de référence — et le premier décodage en temps réel du code de couleur, jusqu’à la distance 9 [7]. Trois réserves s’imposent, que les auteurs eux-mêmes documentent : il s’agit d’un préprint

auto-rapporté, non répliqué indépendamment ; le qualificatif « quasi optimal » est l'évaluation des auteurs, la référence optimale du code de couleur étant extrapolée au-delà de la distance 7 ; et le débit temps réel au-delà de la distance 11 est laissé en travaux futurs. La revendication de primauté sur le code de couleur doit en outre conserver son périmètre exact — « jusqu'à la distance 9 » sur les échelles de temps des supraconducteurs — un décodage temps réel du code de Steane à distance 3 ayant été démontré dès 2021 sur ions piégés, où le cycle se compte en millisecondes.

La question de l'universalité — un même décodeur pour des familles de codes arbitraires — est portée par GraphQEC (Hu *et al.*, USTC, préprint) [8]. Ses auteurs revendiquent le premier décodeur universel applicable aux codes stabilisateurs arbitraires (surface, couleur, QLDPC) et rapportent, sur un code QLDPC de distance 12 à taux d'erreur physique de 0,005, un taux d'erreur logique de $9,55 \times 10^{-5}$, soit une amélioration d'un facteur 18 sur le meilleur décodeur spécialisé antérieur ($1,74 \times 10^{-3}$). Ces chiffres sont auto-rapportés et non répliqués ; surtout, le qualificatif « temps réel » de GraphQEC (environ 157 μ s par cycle dans le préprint) reste incompatible avec le budget microseconde des qubits supraconducteurs, et l'universalité de conception avait un précédent non temps réel (décodeurs génératifs code-agnostiques de 2023). L'apport net — un seul modèle couvrant les codes QLDPC, vers lesquels convergent plusieurs feuilles de route matérielles (section 5.2) — demeure significatif s'il se confirme.

Le tableau 1 récapitule ces jalons en signalant leur statut de publication, qui constitue à nos yeux une variable aussi importante que les performances rapportées.

Tableau 1. – Jalons du décodage neuronal des codes correcteurs d’erreurs quantiques. Le « statut » distingue publication à comité de lecture et préprint auto-rapporté.

Système (année)	Apport principal	Performance rapportée	Statut
RNN-LSTM, Baireuther <i>et al.</i> (2018)	Premier dépassement du MWPM sur données accessibles	Surpasse le MWPM, code de surface	Revue (<i>Quantum</i>)
GNN, Lange <i>et al.</i> (2023)	Décodage sans modèle de bruit explicite	Surpasse l’appariement (simulé)	Revue (PRR)
Transformer-QEC (2023)	Première architecture à attention pour le décodage	Sous MWPM et Union-Find	Préprint
AlphaQubit (2024)	État de l’art en précision, validé sur Sycamore	$2,748 \times 10^{-2}$ à distance 5 (exp.)	Revue (<i>Nature</i>)
Varbanov <i>et al.</i> (2025)	Confirmation indépendante du gain neuronal	Environ -25% d’erreur logique vs MWPM	Revue (PRR)
GraphQEC (2025)	Universalité revendiquée (codes stabilisateurs)	$\times 18$ sur QLDPC distance 12 (auto-rapporté)	Préprint
AlphaQubit (2025-2026)	2 Temps réel $< 1 \mu\text{s}/\text{cycle}$ jusqu’à distance 11	Quasi optimal, surface ≤ 23 , couleur ≤ 27	Préprint

3.2 Calibration et contrôle par apprentissage par renforcement

Un processeur quantique n’est pas un objet statique : ses paramètres de contrôle dérivent continûment, et la calibration — traditionnellement effectuée à l’arrêt, par des procédures dédiées — consomme une fraction croissante du temps machine à mesure que les systèmes grossissent. L’apprentissage par renforcement (RL) transforme ce problème d’ingénierie en problème d’apprentissage en ligne.

Le résultat le plus avancé est celui de Sivak *et al.* (Google Quantum AI, préprint de novembre 2025, révisé en juin 2026), qui unifie calibration et calcul : les événements de détection d’erreur produits par le code correcteur — sous-produit gratuit de tout calcul corrigé — sont réutilisés comme signal d’apprentissage pour un agent RL qui ajuste continûment les paramètres de contrôle *pendant* que le processeur calcule, éliminant l’arrêt pour recalibration [9]. La démonstration expérimentale sur le processeur Willow rapporte une stabilité logique du code de surface

multipliée par 3,5 contre une dérive injectée (dont un facteur 2,4 pour le pilotage RL des seuls contrôles, le complément provenant du pilotage adaptatif du décodeur), ainsi que des records de performance logique : une erreur logique moyenne par cycle de $7,72(9) \times 10^{-4}$ pour le code de surface et $8,19(14) \times 10^{-3}$ pour le code de couleur. Des simulations jusqu’à la distance 15 (environ 40 000 paramètres de contrôle simultanés) suggèrent une vitesse d’optimisation indépendante de la taille du système — propriété démontrée en simulation seulement, dont le transfert au matériel à plus grande échelle reste ouvert. Là encore, le statut de préprint impose l’attribution prudente : les records sont rapportés par les auteurs sur leur propre matériel.

En amont de la boucle de correction, l’apprentissage automatique sert aussi à caractériser le matériel pour mieux le piloter : Genois *et al.* proposent un contrôle optimal de qubits supra-conducteurs dans lequel un modèle des dynamiques du transmon est appris — par apprentissage automatique « inspiré de la physique » — à partir de données expérimentalement accessibles, puis les impulsions de contrôle sont optimisées sur ce modèle entraîné [10]. La fidélité d’environ 99,99 % rapportée pour des portes à un qubit arbitraires est obtenue en simulation numérique détaillée, non sur matériel — distinction que notre protocole de vérification a précisément servi à rétablir (une formulation présentant ce chiffre comme matériel a été réfutée à l’unanimité des vérificateurs ; voir section 8).

3.3 Conception de circuits et découverte de codes

Le troisième front applique l’IA non plus à l’exploitation du matériel, mais à la conception des objets algorithmiques eux-mêmes : circuits et codes correcteurs.

Le résultat emblématique est AlphaTensor-Quantum (Google DeepMind et Quantinuum, *Nature Machine Intelligence*, mars 2025) [11]. Le système reformule la minimisation du nombre de portes T — la ressource dominante du calcul tolérant aux fautes — en un problème de décomposition tensorielle symétrique, attaqué par un agent d’apprentissage par renforcement profond hérité d’AlphaTensor. Sur la suite de circuits arithmétiques testée, il surpasse les méthodes existantes d’optimisation du nombre de portes T, y compris sans recours aux gadgets ; sur les additionneurs binaires, il divise par deux le compte de Toffoli des circuits classiques de référence (de $2n+O(1)$ pour Cuccaro *et al.* [12] à $n+O(1)$), égalant l’état de l’art établi manuellement par Gidney [13] — et, fait notable, en redécouvrant automatiquement, sans connaissance préalable, l’astuce de décalcul par mesure (*measurement-based uncomputation*) qui fonde cette optimisation humaine. Le résultat, publié à comité de lecture puis reproduit et étendu indépendamment [14], souffre de limites d’ingénierie assumées : environ huit heures de calcul par circuit, optimisation du nombre de portes T mais non de leur profondeur, et entraînement par famille de circuits.

La découverte de codes correcteurs par RL progresse en parallèle, sur deux fronts distincts qu’il convient de ne pas fusionner. Olle *et al.* font co-découvrir à un agent (PPO) le code et son circuit d’encodage Clifford, jusqu’à 20 qubits physiques et des codes de distance 5 [15] ; Mauron *et al.*, par simulation projective sur codes tensoriels, trouvent un code optimal environ 10 % du temps après 1 000 essais, contre 0,16 % pour la recherche aléatoire théorique — un facteur 65 [16]. Ces deux travaux, publiés à comité de lecture, restent à des échelles modestes au regard

des codes de distance 15 à 25 visés par les feuilles de route de la tolérance aux fautes, mais établissent la faisabilité du principe.

3.4 Simulation neuronale des systèmes quantiques

Le quatrième front est plus subtil : l’IA y sert à la fois d’outil et d’aiguillon concurrentiel pour le calcul quantique. Les *états quantiques neuronaux* (NQS) — des fonctions d’onde d’essai paramétrées par des réseaux de neurones et optimisées par Monte-Carlo variationnel, introduites par Carleo et Troyer [17] — modélisent avec précision les phénomènes corrélés à N corps dans les systèmes de spins, fermioniques et de qubits, couvrant la recherche d’état fondamental, l’évolution temporelle et l’optimisation de recouvrement [18].

Deux résultats d’expressivité fondent l’intérêt théorique de cette famille : tout état de réseau de tenseurs efficacement contractable se transpose efficacement en réseau de neurones [19], et des machines de Boltzmann restreintes représentent, avec un nombre polynomial de paramètres, des états à intrication en loi de volume que les états de produits matriciels ne peuvent décrire efficacement [20]. Il faut toutefois manier ces résultats avec le distinguo que la littérature impose : ils établissent une expressivité *représentationnelle*, qui ne préjuge pas de l’*entraînabilité* — la capacité à trouver effectivement ces représentations par optimisation, notamment pour les structures de signe des systèmes frustrés, reste le point dur du domaine [18].

Le jalon applicatif récent est l’algorithme NES-VMC de Pfau *et al.* (*Science*, 2024) [21] : une méthode variationnelle pour les plus bas états excités, sans paramètre libre et sans orthogonalisation explicite, qui reformule le problème des états excités en recherche d’état fondamental d’un système étendu. Combinée aux ansätze neuronaux FermiNet [22] et Psiformer, elle retrouve avec précision les énergies d’excitation verticales et les forces d’oscillateur sur une gamme de molécules ; les auteurs revendiquent la première approche d’apprentissage profond atteignant des énergies d’excitation verticales précises — doubles excitations difficiles comprises — à l’échelle du benzène. La portée stratégique de ces méthodes dépasse la chimie numérique : chaque progrès des simulateurs neuronaux classiques relève le seuil que devra franchir un futur avantage quantique en simulation — les NQS ayant déjà servi, dès 2021, à simuler classiquement des circuits QAOA de taille non triviale [23].

4. Le calcul quantique au service de l’IA

Le sens inverse de l’interaction — mobiliser un processeur quantique pour l’apprentissage automatique — est celui qui a le plus alimenté l’enthousiasme grand public, et celui dont le bilan vérifié est, à mi-2026, le plus sobre. Cette section distingue trois strates : les obstacles théoriques qui limitent l’entraînement des modèles quantiques (§4.1), la vague de résultats de *simulabilité classique* qui a érodé les avantages annoncés (§4.2), et le petit noyau d’avantages rigoureusement prouvés, dont on précise l’exact périmètre (§4.3).

4.1 Les plateaux stériles, obstacle structurel

L’entraînement d’un modèle quantique variationnel — réseau de neurones quantique, noyau quantique paramétré, ansatz de VQE ou de QAOA — se heurte au phénomène des *plateaux stériles*. La revue de référence, signée Larocca, Thanasilp, Wang, Sharma, Biamonte, Coles,

Cincio, McClean, Holmes et Cerezo et publiée dans *Nature Reviews Physics* en 2025 [25], en donne la caractérisation consolidée : lorsqu'un modèle présente un plateau stérile, son paysage d'optimisation devient exponentiellement plat et sans relief à mesure que la taille du problème augmente, les gradients étant exponentiellement supprimés avec le nombre de qubits. L'apport conceptuel majeur de cette revue est de montrer que *tous* les composants d'un algorithme variationnel — le choix de l'ansatz, l'état initial, l'observable, la fonction de coût et le bruit matériel — peuvent induire un plateau stérile lorsqu'ils sont mal adaptés : le phénomène n'est donc pas un simple artefact de circuits profonds non structurés, mais une propriété systémique de la conception. Le concept remonte aux travaux fondateurs de McClean *et al.* de 2018 [24], que cette revue prolonge et systématise.

La conséquence pratique est sévère : à mesure que l'on augmente le nombre de qubits pour capter un avantage quantique, le signal d'entraînement s'évanouit exponentiellement, ce qui exigerait un nombre de mesures exponentiel pour estimer les gradients — annulant précisément l'avantage recherché. Les stratégies pour éviter les plateaux stériles (initialisations structurées, ansätze à symétrie, circuits peu profonds) existent, mais elles introduisent un soupçon que la sous-section suivante développe.

4.2 La vague de la simulabilité classique

Le résultat théorique le plus déstabilisant de la période récente est le renversement d'argument formulé par Cerezo *et al.* dans un article de *perspective* dont le titre est délibérément une question : « L'absence prouvable de plateaux stériles implique-t-elle la simulabilité classique ? » [26]. Publié dans *Nature Communications* en 2025 (après une première version en préprint fin 2023), il rassemble, au cas par cas, des indices selon lesquels de nombreux modèles couramment utilisés dont le paysage de perte évite prouvablement les plateaux stériles admettent aussi une *simulation classique* de cette perte, pourvu qu'on autorise une phase initiale — de durée au plus polynomiale — de collecte de données classiques sur l'appareil quantique (un cadre que les auteurs nomment *quantum-enhanced classical simulation*). Le mécanisme invoqué est une malédiction de la dimensionnalité : les plateaux stériles résultent du fait que la dynamique explore un espace exponentiellement grand, et les techniques qui les évitent le font précisément en confinant le problème à un sous-espace de dimension polynomiale — sous-espace qui, n'étant plus exponentiellement grand, redevient classiquement simulable.

La portée exacte de ce résultat doit être énoncée avec soin, car il se prête à la surinterprétation. Il ne s'agit pas d'une preuve universelle que tout modèle quantique variationnel est dequantizable : les auteurs eux-mêmes qualifient leur démarche de « cas par cas » et disent « jeter le doute » (*shed doubt*) plutôt que « réfuter ». Ils bordent explicitement leur thèse de plusieurs réserves : les arguments valent en moyenne (pas nécessairement pour toute instance), des initialisations intelligentes peuvent échapper au cadre, certains modèles sortent des hypothèses, des avantages superpolynomiaux prouvables demeurent possibles, et un dépassement heuristique sur de plus grands appareils n'est pas exclu. La conclusion prudente est que le fardeau de la preuve s'est déplacé : montrer qu'un modèle variationnel est entraînable ne suffit plus à établir qu'il est utile, puisque cette même entraînabilité pourrait signaler sa simulabilité classique.

Ce n’est pas la fin du débat, et il serait malhonnête de le présenter comme tranché. Gil-Fuster, Gyurik, Pérez-Salinas et Dunjko (travaux présentés à ICLR 2025) prouvent au contraire que l’entraînabilité et la non-simulabilité classique ne sont *pas toujours* mutuellement exclusives, et fournissent des constructions explicites de modèles à circuits quantiques paramétrés qui sont à la fois entraînaibles et non dequantizables [27] — tout en précisant qu’ils n’abordent pas l’utilité *pratique* de ces modèles. Le tableau qui se dégage à mi-2026 est donc celui d’une frontière mouvante : la simulabilité classique a considérablement réduit l’espace des avantages plausibles, sans le fermer.

Un cas d’espèce illustre concrètement cette dynamique. Bermejo, Braccia, Rudolph, Holmes, Cincio et Cerezo montrent, dans un travail publié dans *PRX Quantum* en 2026, que les réseaux de neurones convolutifs quantiques (QCNN) initialisés aléatoirement n’exploitent en réalité que l’information contenue dans des mesures de faible corpulence (*low-bodyness*), et que leur action peut donc être simulée classiquement de façon efficace au moyen d’ombres classiques de Pauli — les auteurs poussant la démonstration jusqu’à 1 024 qubits pour une tâche de classification de phases de la matière [28]. Leur conclusion générale porte au-delà des QCNN : les succès heuristiques rapportés du QML pourraient provenir de l’évaluation sur des jeux de données « localement faciles », intrinsèquement classifiables par une information de faible corpulence, de sorte que des jeux de données non triviaux constituent une condition nécessaire à tout progrès authentique de l’apprentissage quantique.

4.3 Les avantages prouvés, et leur périmètre exact

Le tableau n’est pas uniformément négatif : il existe des séparations classique-quantique rigoureusement établies en apprentissage. Leur valeur pour la présente synthèse tient à ce qu’elles délimitent, par leurs hypothèses mêmes, où un avantage est *possible* — et, en creux, où il ne l’est pas.

Le résultat le plus net concerne l’apprentissage à partir de *données quantiques*. Huang *et al.* (*Science*, 2022) prouvent qu’une machine quantique dotée d’une mémoire quantique peut apprendre certaines propriétés de systèmes physiques à partir d’un nombre d’expériences exponentiellement plus petit que toute stratégie conventionnelle mesurant le système puis traitant les résultats classiquement [29]. L’avantage prouvé couvre trois classes de tâches : la prédiction de propriétés de systèmes physiques, l’analyse en composantes principales quantique d’états bruités, et l’apprentissage de modèles approximatifs de dynamiques. Fait remarquable, il a été démontré expérimentalement sur un processeur supraconducteur bruité (NISQ) mobilisant jusqu’à 40 qubits (le stockage simultané de deux copies d’un état d’environ 20 qubits) et de l’ordre de 1 300 portes — établissant que cet avantage ne requiert pas la tolérance aux fautes. Le point décisif, souvent perdu dans la vulgarisation, est le cadre : les données sont *intrinsèquement quantiques*, transduites dans une mémoire quantique et traitées par un ordinateur quantique, par opposition à des données classiques mesurées puis numérisées. C’est la distinction structurante du débat « QML sur données quantiques » contre « QML sur données classiques ».

Sur données classiques, le résultat de référence est celui de Liu, Arunachalam et Temme (*Nature Physics*, 2021), qui construisent un problème de classification pour lequel une méthode à noyaux

quantiques fournit une accélération quantique de bout en bout rigoureusement démontrée, avec un accès uniquement classique aux données [30]. Deux clauses en fixent toutefois le périmètre, et empêchent d’y voir une promesse à court terme. D’abord, la séparation repose sur une hypothèse cryptographique : aucun apprenant classique ne peut faire mieux que le hasard, sous l’hypothèse — largement admise mais non prouvée — de la difficulté du logarithme discret ; il s’agit donc d’une séparation conditionnelle et construite, non d’un problème d’apprentissage naturel. Ensuite, la carte de caractéristiques quantique exige un ordinateur quantique tolérant aux fautes pour être évaluée efficacement : ce n’est pas un résultat NISQ, et il reste hors de portée du matériel de 2026.

Enfin, un résultat de généralisation tempère l’un des obstacles souvent invoqués contre le QML. Caro *et al.* (*Nature Communications*, 2022) établissent des bornes de généralisation pour les modèles d’apprentissage quantique qui dépendent du nombre de portes paramétrées : l’erreur de généralisation d’un modèle à T portes entraînaibles croît au pire comme la racine de T/N (N étant le nombre de points d’entraînement), et s’améliore en racine de K/N lorsque seules K portes sont substantiellement modifiées par l’optimisation [31]. La conséquence est qu’une bonne généralisation est garantie à partir d’un nombre modeste d’exemples — un point positif pour l’entraînabilité statistique, qui n’entame en rien, cependant, les obstacles d’avantage computationnel discutés plus haut.

En somme, le bilan « quantique pour l’IA » à mi-2026 se résume ainsi : des obstacles théoriques structurels (plateaux stériles), une vague de simulabilité classique qui a réduit — sans fermer — l’espace des avantages plausibles, et un noyau d’avantages prouvés dont chacun est soit cantonné aux données quantiques, soit conditionné à une hypothèse cryptographique et à la tolérance aux fautes. Aucun de ces résultats ne soutient l’idée d’un avantage quantique pratique sur les tâches d’apprentissage à données classiques qui dominent l’industrie de l’IA. Cette conclusion prépare directement l’analyse critique de la section 6.

5. La convergence systémique des infrastructures

Si les deux directions algorithmiques progressent à des rythmes contrastés, leur point de rencontre matériel — l’intégration de processeurs quantiques, d’accélérateurs classiques et de piles logicielles d’IA en un système unique — connaît en 2025-2026 une accélération industrielle marquée. Cette section en documente les jalons vérifiés, en séparant scrupuleusement les faits techniques revus par les pairs des revendications commerciales.

5.1 Le couplage HPC-quantique à faible latence

Le fait structurant de la période est la reconnaissance, par l’ensemble des acteurs, que le calcul quantique tolérant aux fautes est un problème de calcul *hybride* : le décodage de correction d’erreurs, la calibration et le contrôle exigent un accélérateur classique massif fonctionnant en boucle fermée serrée avec le processeur quantique, sous une latence de l’ordre de la microseconde.

NVIDIA a formalisé cette vision en annonçant, le 28 octobre 2025 à la GTC de Washington, son architecture ouverte NVQLink, destinée à coupler étroitement le calcul GPU aux processeurs quantiques afin d’exécuter les algorithmes de calibration, de correction d’erreurs et de

contrôle en lien avec un supercalculateur classique [33]. L’annonce revendique une adoption large — 17 fabricants de processeurs quantiques, cinq fabricants de systèmes de contrôle et neuf laboratoires nationaux américains — et une intégration à la plateforme logicielle CUDA-Q. Il s’agit d’un communiqué d’entreprise : les qualificatifs « faible latence, haut débit » y figurent, mais aucune métrique chiffrée de latence, de débit ou de cadence de correction n’y est fournie, et les revendications techniques n’ont pas été validées de façon indépendante.

Les chiffres, eux, apparaissent dans la documentation technique subséquente. Le 16 mars 2026, NVIDIA publie la bibliothèque *cudaq-realtime* (dans la version 0.14 de CUDA-Q), qui construit sur NVQLink une interface d’exécution pour des rappels à latence microseconde entre GPU et contrôleurs quantiques (typiquement des FPGA) [34]. Les auteurs identifient explicitement le décodage de correction d’erreurs comme la contrainte de latence la plus stricte — une tâche d’inférence intensive devant s’exécuter en parallèle du calcul quantique avec une latence minimale. Les latences médianes mesurées pour l’aller-retour d’un appel GPU-FPGA vont d’environ 2,92 μs (mode « Forward » sur un RTX 6000 Blackwell Pro avec ConnectX-7) à environ 8,2 μs (mode « Three-kernel » sur un GB200 NVL4 avec BlueField-3). Ces chiffres portent sur le transport du rappel, non sur un cycle complet de décodage tolérant aux fautes démontré en production ; le statut de la source est un billet technique de fournisseur, non révisé par les pairs.

5.2 Les jalons matériels revus par les pairs

Sous le bruit des annonces, deux résultats de 2024-2025 possèdent le statut le plus fort — la publication dans *Nature* — et méritent d’être distingués comme tels.

Le premier est la démonstration, par Google Quantum AI, d’une correction d’erreurs *sous le seuil* du code de surface, publiée dans *Nature* (en ligne le 9 décembre 2024) sous le titre « Quantum error correction below the surface code threshold » [32]. Sur le processeur Willow de 105 qubits, les auteurs montrent que le taux d’erreur logique est supprimé exponentiellement quand la distance du code augmente, avec un facteur de suppression $\Lambda = 2,14 \pm 0,02$: un qubit logique de distance 7 (101 qubits actifs) atteint un taux d’erreur de 0,143 % $\pm$ 0,003 % par cycle, et sa durée de vie dépasse d’un facteur $2,4 \pm 0,3$ celle de ses meilleurs qubits physiques constitutifs — le fameux passage « au-delà du seuil de rentabilité ». Le décodage y est effectué en temps réel, avec une latence moyenne de 63 μs à la distance 5 pour un temps de cycle de 1,1 μs . C’est, à ce jour, la démonstration la plus rigoureuse que la voie du code de surface franchit le seuil critique en dessous duquel ajouter des qubits *réduit* les erreurs.

Le second est la démonstration, par l’AWS Center for Quantum Computing, d’une correction d’erreurs *efficace en matériel* par qubits bosoniques concaténés, publiée dans *Nature* le 26 février 2025 sous le titre « Hardware-efficient quantum error correction via concatenated bosonic qubits » [38]. L’approche encode l’information dans des *qubits de chat* dont les inversions de bit sont supprimées passivement — de façon exponentielle avec la taille du chat — par un circuit stabilisateur, un code de répétition externe de distance 5 corrigeant les inversions de phase résiduelles ; les taux d’erreur logique mesurés par cycle sont de 1,75(2) % à distance 3 et 1,65(3) % à distance 5. Il importe de noter que le nom commercial « Ocelot » et la revendication d’une

réduction du coût de correction « jusqu’à 90 % » proviennent de l’annonce AWS du 27 février 2025 — une projection prospective et conditionnelle comparée au code de surface — et non de l’article revu par les pairs, qui ne rapporte aucun chiffre de ce type. C’est un exemple net de l’écart, récurrent dans ce domaine, entre le contenu vérifié et son emballage promotionnel.

Du côté d’IBM, le communiqué officiel du 12 novembre 2025 (Quantum Developer Conference) annonce deux processeurs [35]. Nighthawk (120 qubits, 218 coupleurs accordables) offre plus de 20 % de coupleurs supplémentaires que le Heron précédent, vise l’exécution de circuits à 5 000 portes à deux qubits — puis 7 500 fin 2026 et 10 000 en 2027 — et est présenté comme devant livrer un avantage quantique « l’an prochain » (2026), IBM anticipant une confirmation *vérifiée par la communauté* d’ici la fin 2026. Loon, processeur expérimental, démontre pour la première fois l’ensemble des composants clés requis pour la tolérance aux fautes, dont des couplages longue portée sur puce (« c-couplers ») et le décodage temps réel des erreurs par du matériel classique en moins de 480 ns au moyen de codes qLDPC. IBM affirme viser un premier ordinateur quantique tolérant aux fautes à grande échelle d’ici 2029. Deux mises en garde s’imposent, issues de notre vérification : il s’agit d’un communiqué d’entreprise, et les jalons souvent associés à cette feuille de route dans la presse — le processeur nommé « Starling », la cible de « 200 qubits logiques », les noms « Kookaburra » ou « bivariate bicycle code » — *ne figurent pas* dans ce communiqué et relèvent de documents de feuille de route distincts ; nous ne les reprenons donc pas comme faits établis par cette source.

5.3 Une controverse révélatrice : les qubits topologiques

Aucun épisode de la période n’illustre mieux la nécessité de distinguer annonce et résultat que celui des qubits topologiques de Microsoft. Le 19 février 2025, Microsoft annonce sur son blog « Majorana 1 », présenté comme le premier processeur quantique doté d’un « cœur topologique » associant arséniure d’indium et aluminium. Le même jour paraît dans *Nature* l’article scientifique correspondant, « Interferometric single-shot parity measurement in InAs-Al hybrid devices » [36]. Or l’écart entre les deux est frappant, et la vérification le documente précisément : l’article revu par les pairs ne prétend pas avoir démontré des modes de Majorana ni des qubits topologiques — ses auteurs reconnaissent que la mesure ne distingue pas, à elle seule, les modes de Majorana d’états d’Andrieu triviaux à basse énergie. Fait rare, l’équipe éditoriale de *Nature* a joint au dossier de révision une note indiquant explicitement que les résultats du manuscrit ne constituent pas une preuve de la présence de modes de Majorana dans les dispositifs rapportés.

La critique méthodologique la plus documentée est portée par Henry F. Legg dans un *Comment* (préprint arXiv, 26 février 2025) visant le *Topological Gap Protocol* sur lequel repose la démarche de Microsoft [37]. Legg y soutient que le protocole manque d’une définition cohérente d’« écart » ou de « topologique » et emploie des paramètres différents pour les simulations théoriques et pour les données expérimentales, de sorte que la revendication d’une « forte probabilité d’être dans la phase topologique » n’est pas fiable et appelle un réexamen. Des physiciens indépendants relaient ce scepticisme, tandis que Microsoft indique que les preuves complémentaires auraient été obtenues après la soumission de l’article et seront présentées ultérieurement. L’épisode ne

tranche pas la question physique sous-jacente — les qubits topologiques restent une voie de recherche légitime — mais il fixe un enseignement méthodologique central pour toute cette synthèse : le poids probant d’une avancée se juge sur son contenu revu par les pairs, non sur son communiqué.

5.4 Feuilles de route et modèles de langage pour la programmation quantique

Au-delà du matériel, la convergence se manifeste dans les feuilles de route industrielles, qui affichent une remarquable convergence de calendrier vers 2029. IBM vise cette échéance pour un premier système tolérant aux fautes à grande échelle [35] ; Quantinuum annonce, dans un billet du 26 juin 2025, une trajectoire Helios (2025), Sol (2027) puis Apollo (2029), ce dernier présenté comme un ordinateur quantique universel entièrement tolérant aux fautes [39]. Le billet de Quantinuum revendique des jalons expérimentaux — une infidélité d’état magique de 7×10^{-5} (annoncée comme dix fois meilleure que tout résultat publié), une infidélité de porte non-Clifford à deux qubits de 2×10^{-4} , et une démonstration architecturale de 48 qubits logiques obtenus à partir de 98 qubits physiques — qu’il convient de traiter comme des affirmations d’entreprise non arbitrées, les valeurs les plus spectaculaires (10^{-10} à 10^{-14}) étant explicitement des projections simulées. La convergence de ces calendriers vers une même année est un signal industriel notable ; elle ne constitue pas, à elle seule, une preuve technique.

La programmation quantique elle-même devient un terrain d’application des modèles de langage, à travers des assistants de génération de code (à l’image du Qiskit Code Assistant d’IBM) intégrés aux environnements de développement quantiques. Notre protocole de vérification n’a toutefois pas permis d’établir, sur sources primaires, de résultats de performance quantifiés et robustes pour ces outils à la date d’arrêt ; nous signalons donc ce sous-champ comme émergent et réel, mais insuffisamment documenté par des benchmarks primaires vérifiables pour être caractérisé ici au-delà de son existence.

6. Confronter promesses et réalités

Les trois sections précédentes autorisent une confrontation raisonnée entre le discours d’accompagnement du domaine et ce que les sources primaires établissent. Trois voix critiques, toutes antérieures ou concomitantes au corpus étudié et toutes issues de spécialistes de premier plan, en fournissent l’ossature.

La première est celle de John Preskill, qui a forgé en 2018 le terme « NISQ » pour désigner les processeurs de 50 à 100 qubits, bruités et non corrigés, de l’ère en cours [42]. Son diagnostic initial était déjà prudent : un ordinateur de 100 qubits « ne changera pas le monde immédiatement », et le véritable potentiel du calcul quantique passe par la tolérance aux fautes. Sa réévaluation de 2025, « Beyond NISQ: The Megaquop Machine » [43], durcit ce diagnostic sur la foi de sept années d’expérience : aucune application NISQ à valeur commerciale n’a démontré d’avantage quantique face au meilleur matériel classique exécutant les meilleurs algorithmes, et il n’existe pas d’argument théorique convaincant qu’on trouvera de telles applications sans codes correcteurs et calcul tolérant aux fautes. Preskill y définit une nouvelle cible — la « megaquop machine », capable d’un million d’opérations quantiques fiables — comme le seuil marquant la

sortie de l'ère NISQ. Ce jugement, venant de l'auteur même du vocabulaire de la période, pèse lourd : il replace l'horizon des applications utiles au-delà du matériel actuel.

La deuxième voix est celle de Scott Aaronson, dont la mise en garde « Read the fine print » (*Nature Physics*, 2015) garde une actualité intacte [41]. Analysant la famille d'algorithmes de type HHL (résolution quantique de systèmes linéaires) qui sous-tend une grande part des promesses de QML, Aaronson montre que l'accélération exponentielle apparente repose sur quatre conditions — la préparation efficace de l'état d'entrée, l'application efficace de l'évolution, le bon conditionnement de la matrice, et la lecture de la sortie — dont chacune, si elle n'est pas satisfaite, suffit à annuler l'avantage. La sortie de HHL n'étant qu'un état quantique, en extraire une information exploitable requiert souvent de répéter l'algorithme un nombre de fois qui restaure le coût classique. La règle qu'il en tire — un avantage exponentiel exige à la fois une préparation rapide de la superposition *et* l'absence d'un procédé classique rapide produisant la même distribution — préfigure très exactement la logique des résultats de simulabilité classique de 2024-2026 (section 4.2). Elle distingue aussi nettement le QML de l'algorithme de factorisation de Shor, dont l'avantage ne souffre d'aucune de ces réserves.

La troisième voix est celle de Matthias Troyer et de ses coauteurs Hoeffler et Häner, dont l'analyse « Disentangling Hype from Practicality » (*Communications of the ACM*, 2023) fournit la grille économique la plus citée du domaine [40]. Leur thèse : les ordinateurs quantiques seront pratiques pour des problèmes « à gros calcul sur petites données », non pour le traitement de données massives. La raison est quantitative. Une porte quantique logique (de l'ordre de 10 μ s) est environ quatre ordres de grandeur plus lente que le cycle d'un GPU classique (environ 0,7 ns), et cet écart de vitesse constant, supérieur à un facteur 10^{10} , doit être remboursé par l'avantage asymptotique de l'algorithme avant tout gain réel. Une accélération quadratique — celle de l'algorithme de Grover — n'y suffit pas : les surcoûts de la correction d'erreurs et la lenteur des horloges quantiques repoussent le point de rentabilité à des échelles hors d'atteinte. Seules des accélérations super-quadratiques, idéalement exponentielles, sur des problèmes à faible volume de données, franchissent le seuil ; les auteurs désignent la chimie et la science des matériaux comme les candidats les plus prometteurs, et rangent explicitement l'entraînement de nombreux modèles d'apprentissage automatique, l'accélération de la conception de médicaments par Grover et diverses simulations parmi les usages qui n'atteindront pas l'avantage quantique dans un avenir prévisible avec les algorithmes actuels.

Ces trois analyses convergent vers une même conclusion, que le corpus vérifié de cet article corrobore de bout en bout : l'interaction féconde et démontrée entre IA et quantique passe aujourd'hui par la direction IA $\rightarrow$ Q (sections 3) et par la convergence des infrastructures (section 5), tandis que la direction Q $\rightarrow$ IA sur données classiques — celle qui a le plus nourri l'imaginaire du « ML quantique » — demeure sans avantage pratique établi. Cette convergence de jugements ne clôt pas l'avenir : elle qualifie le présent.

Il faut enfin situer ce présent dans son échelle économique, sans confondre projection et mesure. Le *Quantum Technology Monitor 2025* de McKinsey (« The year of quantum », 24 juin 2025) estime que les trois piliers des technologies quantiques — calcul, communication, détection —

pourraient générer jusqu’à 97 milliards de dollars de revenus mondiaux d’ici 2035 (dont 28 à 72 pour le seul calcul), et jusqu’à 198 milliards d’ici 2040 ; il chiffre à environ 2,0 milliards de dollars l’investissement privé et public dans les jeunes pousses quantiques en 2024, en hausse de 50 % sur 2023 [44]. Ces chiffres sont des estimations d’analyste, présentées en fourchettes larges du fait de l’incertitude technique, et le haut de fourchette (97 milliards) ne doit pas être lu comme une prévision ponctuelle. Ils mesurent l’ampleur du pari collectif — considérable — bien plus qu’ils n’anticipent le calendrier de sa réalisation.

7. Questions ouvertes

L’état des lieux qui précède laisse en suspens quatre questions dont la résolution, dans les cinq prochaines années, déterminera la trajectoire de l’interaction IA-quantique.

Le décodage neuronal tiendra-t-il à l’échelle de la tolérance aux fautes ? Les décodeurs de type AlphaQubit atteignent le temps réel jusqu’à la distance 11 [7], mais la tolérance aux fautes pratique exigera des distances de 15 à 25, régime où le débit temps réel reste, de l’aveu des auteurs, un problème ouvert, et où les besoins en données d’entraînement croissent fortement. La question du passage à l’échelle — en débit comme en coût d’entraînement — n’est pas tranchée.

L’indépendance en taille de la calibration par RL se transférera-t-elle au matériel ?

La propriété la plus prometteuse du cadre « calibrer sans arrêter » — une vitesse d’optimisation indépendante de la taille du système — n’est démontrée qu’en simulation, jusqu’à environ 40 000 paramètres [9]. Son maintien sur du matériel réel, aux distances supérieures et sur les durées d’exécution d’algorithmes tolérants aux fautes complets, reste à établir.

La frontière de la simulabilité classique se stabilisera-t-elle, et où ? Le débat ouvert par Cerezo *et al.* [26] et nuancé par Gil-Fuster *et al.* [27] ne convergera que lorsqu’on saura caractériser précisément les modèles quantiques à la fois entraînaibles, non simulables classiquement *et* pratiquement utiles. À défaut, le QML sur données classiques restera un programme de recherche sans jalon d’avantage crédible. La piste des données intrinsèquement quantiques [29] paraît, à l’inverse, la plus susceptible de livrer un avantage tangible — reste à identifier des tâches d’intérêt appliqué qui s’y prêtent.

Les calendriers 2029 seront-ils tenus, et sur quels critères les jugera-t-on ? La convergence des feuilles de route industrielles vers 2029 [35,39] est un fait social remarquable ; elle n’est pas un fait technique. L’épisode des qubits topologiques (section 5.3) rappelle que le critère décisif n’est pas l’annonce mais la démonstration revue par les pairs et, idéalement, répliquée. La communauté aura besoin de protocoles partagés pour distinguer un avantage quantique « vérifié » d’un avantage revendiqué — l’engagement même d’IBM à une confirmation « par la communauté » d’ici fin 2026 en souligne le besoin.

8. Méthodologie et limites

8.1 Protocole de recherche et de vérification

Cette synthèse repose sur un protocole de recherche documentaire et de vérification exécuté en juillet 2026 au moyen d’un harnais multi-agents, en deux temps. Une première passe, en cinq phases — décomposition de la question en angles de recherche ; recherche web parallèle, un agent par angle ; collecte des sources et extraction d’énoncés falsifiables liés à leur source primaire ; vérification adversariale à trois votes ; synthèse — a extrait 122 énoncés candidats de 25 sources et en a soumis 25 à la vérification : 22 ont été confirmés à l’unanimité des trois vérificateurs et 3 réfutés. Dans cette phase de vérification, chaque énoncé est confié à trois agents indépendants explicitement chargés de le *réfuter* contre la source primaire (récupération du texte intégral ou de l’abstract, contrôle des citations verbatim, recherche de contre-exemples et de travaux contradictoires) ; un énoncé n’est retenu que si aucune majorité ne le réfute.

Une seconde passe, ciblée sur les volets « quantique pour l’IA », convergence systémique et analyses critiques, a d’abord échoué en raison d’une saturation de quota qui a interrompu tous les vérificateurs, ne laissant que les énoncés extraits et leurs sources. Conformément à un mode de repli documenté, nous avons alors procédé à une **contre-vérification directe**, source par source : vingt agents ont récupéré chacun une source primaire (article de revue, préprint, communiqué officiel), confirmé les éléments bibliographiques exacts (auteurs, revue, volume, pages, DOI, date), relevé les citations verbatim à l’appui de chaque énoncé, et signalé tout écart. Ce sont les résultats de cette contre-vérification directe qui étayent les sections 4 à 7. Ce mode dégradé — vérification par confrontation directe plutôt que par vote adversarial — est signalé ici en toute transparence ; il a néanmoins permis de corriger plusieurs erreurs matérielles et de préciser de nombreux statuts de publication.

La valeur du volet adversarial et de la contre-vérification se mesure aux corrections qu’ils ont produites. Une formulation attribuant au matériel une fidélité de 99,99 % obtenue en simulation (§3.2) a été réfutée et corrigée ; une revendication de complexité temporelle linéaire pour GraphQEC a été écartée ; l’identifiant arXiv d’un article majeur (Troyer *et al.*) fourni au départ était erroné et a été rectifié ; les noms de feuille de route « Starling » et « 200 qubits logiques » ont été retirés de l’énoncé sur IBM faute de figurer dans la source citée ; le nom « Ocelot » et la réduction « 90 % » ont été correctement réattribués à l’annonce AWS plutôt qu’à l’article *Nature* ; et le statut de plusieurs préprints (Cerezo *et al.*, Gil-Fuster *et al.*, Bermejo *et al.*) a été mis à jour vers leur publication à comité de lecture effective.

8.2 Limites

Cette méthodologie appelle cinq réserves. Premièrement, la vérification porte sur la *fidélité aux sources primaires*, non sur la validité scientifique ultime de celles-ci : un préprint fidèlement cité reste un préprint, et nous signalons systématiquement ce statut. Deuxièmement, les résultats les plus récents de la direction IA→Q (AlphaQubit 2, calibration RL sur Willow, GraphQEC) sont auto-rapportés par leurs auteurs et non répliqués indépendamment à la date d’arrêt ; leurs chiffres sont des revendications documentées, pas des faits consolidés. Troisièmement,

plusieurs sources primaires (pages d'éditeurs sous authentification, communiqués) n'ont pu être lues directement et ont été vérifiées via des miroirs en accès ouvert (préprints arXiv identiques, PubMed Central, Crossref) ou des republications fidèles ; ce point est noté pour chaque source concernée. Quatrièmement, la couverture, bien qu'étendue, procède d'un échantillonnage : un domaine qui publie quotidiennement ne se laisse pas clore, et l'arrêt au 3 juillet 2026 est une coupe dans un flux — les préprints cités (versions v2 à v4) peuvent évoluer avant publication. Cinquièmement, le sous-champ des modèles de langage pour la programmation quantique et certains chiffres de marché (projections d'analystes) sont rapportés avec une confiance moindre, faute de sources primaires quantifiées et arbitrées ; ils sont présentés comme tels.

9. Conclusion

Au terme de cet état des lieux, l'« IA quantique » se révèle non pas un objet unique mais un faisceau de programmes dont il faut, avant tout, ne pas confondre les maturités. La direction « IA pour le quantique » est aujourd'hui la plus aboutie : elle a livré des décodeurs neuronaux plus précis que les meilleures méthodes classiques et validés dans *Nature*, un cadre d'apprentissage par renforcement qui calibre un processeur en cours de calcul, une conception automatique de circuits qui égale l'état de l'art humain, et des simulateurs neuronaux qui rivalisent avec la chimie quantique établie. Ces résultats partagent une même vertu : l'IA y agit sur du matériel classique, contre des objectifs mesurables, avec des références de comparaison nettes — d'où leur solidité.

La direction inverse, le calcul quantique au service de l'apprentissage, offre un contraste instructif. Les obstacles théoriques y sont profonds — plateaux stériles, simulabilité classique des modèles entraînaux — et le noyau d'avantages rigoureusement prouvés se cantonne aux données intrinsèquement quantiques ou à des constructions conditionnées par la cryptographie et la tolérance aux fautes. Sur les données classiques qui font le quotidien de l'IA industrielle, aucun avantage quantique pratique n'est établi à mi-2026, et les voix les plus autorisées du domaine — Preskill, Aaronson, Troyer — convergent pour en expliquer les raisons structurelles. Ce n'est pas une condamnation : c'est une délimitation, qui oriente l'effort vers les données quantiques et la simulation, là où la physique elle-même fournit le problème.

Entre ces deux directions algorithmiques, la convergence des infrastructures avance à un rythme industriel — couplage HPC-quantique à faible latence, décodage temps réel hétérogène, feuilles de route alignées sur 2029 — mais son calendrier demeure suspendu à des jalons scientifiques qui ne sont pas tous acquis, comme l'a rappelé la controverse sur les qubits topologiques. La leçon transversale de cette synthèse est d'ordre méthodologique autant que scientifique : dans un domaine où l'annonce précède si souvent la démonstration, la valeur d'une avancée se juge à son contenu revu par les pairs et, idéalement, répliqué — jamais à son communiqué. C'est cette discipline, appliquée énoncé par énoncé, que le présent article a cherché à mettre en œuvre, et c'est elle qui distingue, dans l'interaction entre intelligence artificielle et informatique quantique, ce qui est fait de ce qui est promis.

Remerciements

L’auteur remercie les équipes dont les publications primaires, librement accessibles, rendent possible ce type de synthèse vérifiée. La recherche documentaire, la contre-vérification des énoncés et la mise en forme ont été assistées par des agents d’intelligence artificielle (Claude, Anthropic), sous direction et responsabilité éditoriales humaines. Les erreurs résiduelles demeurent celles de l’auteur.

Références

- [1] P. Baireuther, T. E. O’Brien, B. Tarasinski, C. W. J. Beenakker, « Machine-learning-assisted correction of correlated qubit errors in a topological code », *Quantum* **2**, 48 (2018). DOI 10.22331/q-2018-01-29-48.
- [2] M. Lange, P. Havström, B. Srivastava *et al.*, « Data-driven decoding of quantum error correcting codes using graph neural networks », préprint arXiv:2307.01241 (2023).
- [3] H. Wang, P. Liu *et al.*, « Transformer-QEC : Quantum Error Correction Code Decoding with Transferable Transformers », préprint arXiv:2311.16082 (2023).
- [4] A. Alexeev *et al.*, « Artificial Intelligence for Quantum Error Correction : A Comprehensive Review », préprint arXiv:2411.09131 (2024).
- [5] B. M. Varbanov *et al.*, « Neural network decoder for near-term surface-code experiments », *Physical Review Research* **7**, 013029 (2025).
- [6] J. Bausch, A. W. Senior, F. J. H. Heras *et al.* (Google DeepMind, Google Quantum AI), « Learning high-accuracy error decoding for quantum processors » (AlphaQubit), *Nature* **635**, 834-840 (2024). DOI 10.1038/s41586-024-08148-8 ; préprint arXiv:2310.05900.
- [7] Google DeepMind, Google Quantum AI, « AlphaQubit 2 : real-time neural-network decoding of surface and color codes at scale », préprint arXiv:2512.07737 (déc. 2025, rév. mars 2026).
- [8] Y. Hu *et al.* (USTC), « GraphQEC : a universal real-time decoder for stabilizer codes », préprint arXiv:2502.19971 (2025).
- [9] V. Sivak *et al.* (Google Quantum AI), « Calibrating without stopping : reinforcement learning for in-situ control of a quantum error-correcting code », préprint arXiv:2511.08493 (nov. 2025, rév. juin 2026).
- [10] É. Genois, N. Stevenson, N. Goss, I. Siddiqi, A. Blais, « Physics-inspired machine learning for quantum optimal control of superconducting qubits », préprint arXiv:2410.22603 (2024).
- [11] F. J. R. Ruiz, T. Laakkonen, J. Bausch *et al.* (Google DeepMind, Quantinuum), « Quantum circuit optimization with AlphaTensor », *Nature Machine Intelligence* **7**, 374-385 (2025). DOI 10.1038/s42256-025-01001-1 ; préprint arXiv:2402.14396.
- [12] S. A. Cuccaro, T. G. Draper, S. A. Kutin, D. P. Moulton, « A new quantum ripple-carry addition circuit », préprint quant-ph/0410184 (2004).

- [13] C. Gidney, « Halving the cost of quantum addition », *Quantum* **2**, 74 (2018). DOI 10.22331/q-2018-06-18-74.
- [14] Reproduction et extension indépendantes d'AlphaTensor-Quantum, *Nature Machine Intelligence*, DOI 10.1038/s42256-025-01166-9 (2025).
- [15] J. Olle, R. Zen, M. Puviani, F. Marquardt, « Simultaneous discovery of quantum error correction codes and encoders with a reinforcement learning agent », *npj Quantum Information* **10**, 126 (2024) ; préprint arXiv:2311.04750.
- [16] S. Maunon, T. Farrelly, T. M. Stace, « Optimization of tensor network codes with reinforcement learning », *New Journal of Physics* **26**, 023024 (2024) ; préprint arXiv:2305.11470.
- [17] G. Carleo, M. Troyer, « Solving the quantum many-body problem with artificial neural networks », *Science* **355**, 602-606 (2017). DOI 10.1126/science.aag2302.
- [18] M. Medvidović, J. Robledo Moreno, « Neural-network quantum states for many-body physics », *European Physical Journal Plus* **139**, 631 (2024) ; préprint arXiv:2402.11014.
- [19] O. Sharir, A. Shashua, G. Carleo, « Neural tensor contractions and the expressive power of deep neural quantum states », *Physical Review B* **106**, 205136 (2022).
- [20] D.-L. Deng, X. Li, S. Das Sarma, « Quantum entanglement in neural network states », *Physical Review X* **7**, 021021 (2017).
- [21] D. Pfau, S. Axelrod, H. Sutterud, I. von Glehn, J. S. Spencer, « Accurate computation of quantum excited states with neural networks » (NES-VMC), *Science* **385**, eadn0137 (2024). DOI 10.1126/science.adn0137 ; préprint arXiv:2308.16848.
- [22] D. Pfau, J. S. Spencer, A. G. de G. Matthews, W. M. C. Foulkes, « Ab initio solution of the many-electron Schrödinger equation with deep neural networks » (FermiNet), *Physical Review Research* **2**, 033429 (2020).
- [23] M. Medvidović, G. Carleo, « Classical variational simulation of the Quantum Approximate Optimization Algorithm », *npj Quantum Information* **7**, 101 (2021).
- [24] J. R. McClean, S. Boixo, V. N. Smelyanskiy, R. Babbush, H. Neven, « Barren plateaus in quantum neural network training landscapes », *Nature Communications* **9**, 4812 (2018). DOI 10.1038/s41467-018-07090-4.
- [25] M. Larocca, S. Thanasilp, S. Wang, K. Sharma, J. Biamonte, P. J. Coles, L. Cincio, J. R. McClean, Z. Holmes, M. Cerezo, « Barren plateaus in variational quantum computing », *Nature Reviews Physics* **7**, 174-189 (2025). DOI 10.1038/s42254-025-00813-9 ; préprint arXiv:2405.00781.
- [26] M. Cerezo, M. Larocca, D. García-Martín *et al.*, « Does provable absence of barren plateaus imply classical simulability? », *Nature Communications* **16**, 7907 (2025). DOI 10.1038/s41467-025-63099-6 ; préprint arXiv:2312.09121.

- [27] E. Gil-Fuster, C. Gyurik, A. Pérez-Salinas, V. Dunjko, « On the relation between trainability and dequantization of variational quantum learning models », *Proc. Thirteenth International Conference on Learning Representations (ICLR 2025)* ; préprint arXiv:2406.07072.
- [28] P. Bermejo, P. Braccia, M. S. Rudolph, Z. Holmes, L. Cincio, M. Cerezo, « Quantum Convolutional Neural Networks are Effectively Classically Simulable », *PRX Quantum* **7**, 020304 (2026) ; préprint arXiv:2408.12739.
- [29] H.-Y. Huang, M. Broughton, J. Cotler *et al.*, « Quantum advantage in learning from experiments », *Science* **376**, 1182-1186 (2022). DOI 10.1126/science.abn7293 ; préprint arXiv:2112.00778.
- [30] Y. Liu, S. Arunachalam, K. Temme, « A rigorous and robust quantum speed-up in supervised machine learning », *Nature Physics* **17**, 1013-1017 (2021). DOI 10.1038/s41567-021-01287-z.
- [31] M. C. Caro, H.-Y. Huang, M. Cerezo, K. Sharma, A. Sornborger, L. Cincio, P. J. Coles, « Generalization in quantum machine learning from few training data », *Nature Communications* **13**, 4919 (2022). DOI 10.1038/s41467-022-32550-3.
- [32] Google Quantum AI *et al.* (R. Acharya *et al.*), « Quantum error correction below the surface code threshold », *Nature* **638**, 920-926 (2025, en ligne 9 déc. 2024). DOI 10.1038/s41586-024-08449-y ; préprint arXiv:2408.13687.
- [33] NVIDIA Corporation, « NVIDIA Unveils NVQLink to Connect Quantum Processors With AI Supercomputers », communiqué de presse, NVIDIA Newsroom, 28 octobre 2025.
- [34] NVIDIA (S. Caldwell, T. Nguyen, B. Schmitt *et al.*), « Launching cudaq-realtime », blog technique CUDA-Q, 16 mars 2026.
- [35] IBM Corporation, « IBM Delivers New Quantum Processors, Software, and Algorithm Breakthroughs on Path to Advantage and Fault Tolerance » (Nighthawk, Loon), communiqué de presse, IBM Newsroom, 12 novembre 2025.
- [36] Microsoft Quantum (M. Aghaee *et al.*), « Interferometric single-shot parity measurement in InAs-Al hybrid devices », *Nature* **638**, 651-655 (2025). DOI 10.1038/s41586-024-08445-2.
- [37] H. F. Legg, « Comment on “InAs-Al hybrid devices passing the topological gap protocol” (Microsoft Quantum, Phys. Rev. B 107, 245423, 2023) », préprint arXiv:2502.19560 (26 février 2025).
- [38] H. Putterman, K. Noh, C. T. Hann *et al.* (AWS Center for Quantum Computing), « Hardware-efficient quantum error correction via concatenated bosonic qubits » (puce Ocelot), *Nature* **638**, 927-934 (2025). DOI 10.1038/s41586-025-08642-7 ; préprint arXiv:2409.13025.
- [39] Quantinuum, « Quantinuum Overcomes Last Major Hurdle to Deliver Scalable Universal Fault-Tolerant Quantum Computers by 2029 » (Helios, Sol, Apollo), billet de blogue officiel, 26 juin 2025.

- [40] T. Hoeffler, T. Häner, M. Troyer, « Disentangling Hype from Practicality : On Realistically Achieving Quantum Advantage », *Communications of the ACM* **66**(5), 82-87 (2023). DOI 10.1145/3571725 ; préprint arXiv:2307.00523.
- [41] S. Aaronson, « Read the fine print », *Nature Physics* **11**, 291-293 (2015). DOI 10.1038/nphys3272.
- [42] J. Preskill, « Quantum Computing in the NISQ era and beyond », *Quantum* **2**, 79 (2018). DOI 10.22331/q-2018-08-06-79 ; préprint arXiv:1801.00862.
- [43] J. Preskill, « Beyond NISQ : The Megaquop Machine », *ACM Transactions on Quantum Computing* (2025). DOI 10.1145/3723153 ; préprint arXiv:2502.17368.
- [44] McKinsey & Company, « The year of quantum : From concept to reality in 2025 » (Quantum Technology Monitor 2025), McKinsey Digital, 24 juin 2025.